

# TREINAMENTO DE REDE MLP PARA CLASSIFICAÇÃO DE RISCO DE BURNOUT NO TRABALHO

**Anderson Luis Marchi**  
Instituto Federal Catarinense

andersonlmarchi@gmail.com

## 1. Introdução

O presente estudo utiliza o dataset *Mental Health & Burnout in the Workplace*, disponibilizado originalmente no Kaggle (2025). Esse conjunto de dados contém respostas de profissionais do setor de tecnologia a um questionário relacionado à saúde mental no ambiente de trabalho. O objetivo principal é investigar fatores associados à presença de transtornos mentais, ao suporte organizacional e às barreiras percebidas para buscar tratamento.

Esse dataset pode ser utilizado em pesquisas de aprendizado de máquina, pois combina variáveis demográficas, comportamentais e de percepção subjetiva, o que permite a construção de modelos preditivos voltados à análise de saúde mental e risco de burnout em contextos corporativos.

## 2. Desenvolvimento da solução

O dataset contém 3000 registros de indivíduos e um conjunto de variáveis categóricas e numéricas. Entre os principais grupos de atributos, destacam-se:

- **Variáveis demográficas:** idade, gênero, país de residência.
- **Variáveis profissionais:** tipo de empresa (startup, grande porte), número de funcionários, regime de trabalho remoto ou presencial.
- **Variáveis sobre saúde mental:** histórico de doença mental, diagnóstico precoce, percepção do impacto da saúde mental no trabalho.
- **Variáveis sobre suporte organizacional:** existência de políticas de apoio, abertura da empresa para discutir saúde mental, facilidade para solicitar afastamento.
- **Variáveis de percepção social:** estigma percebido, reação de colegas e gestores, disposição em falar sobre saúde mental com superiores.

De modo geral, o dataset possui um caráter misto, conforme visualizado na Figura 1 a seguir, com dados qualitativos (nominais e ordinais) e quantitativos sendo um modelo perfeito para ser usado em MLP.

	A	B	C	D	E	F	G	H	I	J	K
1	EmployeeID	Age	Gender	Country	JobRole	Department	YearsAtCompany	WorkHoursPerWeek	RemoteWork	BurnoutLevel	JobSatisfaction
2	1001	50	Male	UK	Sales Associate	HR	14	47	No	3.37	5.06
3	1002	36	Male	Germany	Software Engineer	IT	1	59	Hybrid	7.39	2.0
4	1003	29	Non-binary	India	IT Admin	IT	13	59	Hybrid	7.1	7.17
5	1004	42	Male	Australia	HR Specialist	IT	15	31	Yes	4.18	3.76
6	1005	40	Male	Brazil	Customer Support	Support	6	34	Yes	8.28	2.34
7	1006	44	Prefer not to say	Germany	Project Manager	Support	3	58	Hybrid	3.12	4.81
8	1007	32	Prefer not to say	USA	Software Engineer	Engineering	17	30	Hybrid	5.15	9.68
9	1008	32	Male	Canada	Customer Support	Marketing	4	39	No	5.25	4.7
10	1009	45	Prefer not to say	Canada	Marketing Manager	Sales	5	49	Hybrid	4.07	4.13
11	1010	57	Prefer not to say	Brazil	Software Engineer	Engineering	6	59	Hybrid	9.59	5.0
12	1011	45	Male	Germany	Sales Associate	Sales	14	39	Yes	7.27	1.11
13	1012	24	Non-binary	Brazil	Data Scientist	Marketing	0	34	Hybrid	5.85	2.2
14	1013	43	Male	Canada	HR Specialist	Support	3	47	Hybrid	5.59	8.65
15	1014	23	Prefer not to say	India	IT Admin	Sales	0	50	Yes	2.43	9.8
16	1015	45	Non-binary	Germany	Marketing Manager	IT	10	55	No	4.35	2.42
17	1016	51	Female	UK	Marketing Manager	HR	17	44	Yes	7.05	5.82
18	1017	59	Non-binary	India	Project Manager	Support	13	49	Yes	9.32	9.7
19	1018	23	Prefer not to say	India	Software Engineer	IT	10	37	Hybrid	8.35	2.41
20	1019	42	Non-binary	India	Project Manager	IT	9	46	Hybrid	3.7	2.68
21	1020	54	Male	UK	Data Scientist	Marketing	16	41	No	4.91	9.34
22	1021	33	Female	USA	Customer Support	Support	3	50	Hybrid	1.75	7.35
23	1022	43	Female	Australia	Data Scientist	HR	14	59	No	1.92	2.37
24	1023	46	Female	Brazil	Customer Support	Engineering	15	59	No	5.23	4.54
25	1024	48	Prefer not to say	Canada	Project Manager	IT	20	56	No	5.77	1.51
26	1025	49	Prefer not to say	Brazil	HR Specialist	IT	12	41	No	3.38	4.89
27	1026	37	Female	Germany	Data Scientist	Sales	8	55	Hybrid	6.79	8.0
28	1027	36	Non-binary	USA	Project Manager	Marketing	10	30	Yes	7.33	5.99
29	1028	24	Female	Germany	Software Engineer	Engineering	10	55	Yes	3.69	6.83
30	1029	58	Non-binary	Brazil	Project Manager	Engineering	5	55	Hybrid	7.83	3.94
31	1030	28	Non-binary	Canada	Project Manager	Sales	0	33	Hybrid	2.85	2.45

Figura 1: Amostra do dataset aberto em software de planilha

Nele podemos utilizar diferentes tarefas de aprendizado supervisionado, como:

- **Classificação binária:** prever se um indivíduo possui histórico de doença mental ou se pode ter um burnout (*yes/no*).
- **Classificação multiclasse:** prever a abertura da empresa para discutir saúde mental (aberta, parcialmente aberta, fechada).
- **Predição de suporte organizacional:** identificar empresas com maior ou menor probabilidade de oferecer políticas de saúde mental.

Para este fim, uma rede neural do tipo MLP é adequada, pois consegue capturar relações não lineares entre múltiplas variáveis categóricas e numéricas. O processo típico de modelagem inclui:

1. **Pré-processamento:** limpeza de dados, codificação de variáveis categóricas e normalização.
2. **Divisão em treino e teste:** usado na proporção 70/30.
3. **Treinamento da MLP:** composta por uma camada de entrada (features), uma ou mais camadas ocultas (com funções de ativação como *ReLU*), e uma camada de saída (sigmóide para classificação binária ou softmax para multiclasse).
4. **Avaliação do modelo:** métricas como *accuracy*, *precision*, *recall* e *F1-score*.

Nos treinamentos foram utilizadas várias configurações distintas para termos uma amostra de qual delas teríamos a melhor acurácia e aplicação do F1-score para

definir a melhor delas. Abaixo temos o trecho do código onde definimos as configurações:


```
test_size = 30
random_state = 42
configs = [
    {"name": "MLP-1", "layers": [32, 16], "dropout": 0.2, "epochs": 30, "batch_size": 32},
    {"name": "MLP-2", "layers": [64, 32], "dropout": 0.3, "epochs": 40, "batch_size": 64},
    {"name": "MLP-3", "layers": [128, 64, 32], "dropout": 0.4, "epochs": 50, "batch_size": 128},
]
```

**Figura 2: Configurações usadas no treinamento da MLP**


Nota-se que foi usado a configuração de Dropout para o treinamento da rede. Esse dropout é uma técnica de regularização usada em redes neurais para evitar o overfitting, que em resumo desliga a porcentagem de neurônios durante o processo de treinamento para que ela possua várias arquiteturas ligeiramente diferentes, evitando que ela “decore” os dados de treino e melhore a generalização para novos dados .

## 4. Resultados


O modelo de classificação foi treinado utilizando três abordagens distintas, variando hiperparâmetros e estratégias de regularização. Em cada experimento, avaliamos o desempenho por meio da acurácia e da perda durante as épocas de treinamento e validação, permitindo identificar possíveis sinais de overfitting. Para complementar a avaliação, foram geradas as matrizes de confusão de cada treinamento, possibilitando observar não apenas a taxa de acertos globais, mas também como o modelo se comportou em cada classe individualmente.



**Figura 3: Matriz de confusão da configuração 1**




**Figura 4: Matriz de confusão da configuração 2**



**Figura 5: Matriz de confusão da configuração 3**

Esse recurso foi essencial para identificar classes em que o modelo apresentou maior dificuldade, destacando assimetrias na classificação que não seriam visíveis apenas pela métrica de acurácia. Por fim, os gráficos de perda e acurácia ao longo das épocas foram incluídos para cada versão do treinamento, porém, no gráfico representado pela Figura 6 a seguir, trouxe apenas os dados do treinamento com a melhor configuração (por F1 da classe 1) que foi o MLP-1 com 0.9713 seguido de 0.9697 do MLP-3 e por último o MLP-2 com 0.9662.



**Figura 6: Tela de listagem de tickets do UVdesk**

Esses gráficos permitem verificar a consistência entre treino e validação, bem como avaliar o ponto de saturação do modelo. Em conjunto com as matrizes de confusão, eles fornecem uma visão mais completa do desempenho alcançado em cada cenário, servindo de base para selecionar a configuração mais adequada e orientar ajustes futuros.

## 5. Referências

KAGGLE. **Mental Health & Burnout in the Workplace**. Disponível em: <https://www.kaggle.com/datasets/khushikyad001/mental-health-and-burnout-in-the-workplace>. Acesso em: 27 ago. 2025.